

维基百科

自由的百科全书

拟牛顿法

维基百科，自由的百科全书

拟牛顿法是一种以牛顿法为基础设计的，求解非线性方程组或连续的最优化问题函数的零点或极大、极小值的算法。当牛顿法中所要求计算的雅可比矩阵或Hessian矩阵难以甚至无法计算时，拟牛顿法便可派上用场。

搜索极值

与牛顿法相同，拟牛顿法是用一个二次函数以近似目标函数 $f(\boldsymbol{x})$ 。 $f(\boldsymbol{x})$ 的二阶泰勒展开是

$$f(\boldsymbol{x}_k + \Delta \boldsymbol{x}) \approx f(\boldsymbol{x}_k) + \nabla f(\boldsymbol{x}_k)^T \Delta \boldsymbol{x} + \frac{1}{2} \Delta \boldsymbol{x}^T \boldsymbol{B} \Delta \boldsymbol{x}.$$

其中， ∇f 表示 $f(\boldsymbol{x})$ 的梯度， \boldsymbol{B} 表示Hessian矩阵 $\mathbf{H}[f(\boldsymbol{x})]$ 的近似。梯度 ∇f 可进一步近似为下列形式

$$\nabla f(\boldsymbol{x}_k + \Delta \boldsymbol{x}) \approx \nabla f(\boldsymbol{x}_k) + \boldsymbol{B} \Delta \boldsymbol{x}.$$

令上式等于0，计算出Newton步长 $\Delta \boldsymbol{x}$,

$$\Delta \boldsymbol{x} = -\boldsymbol{B}^{-1} \nabla f(\boldsymbol{x}_k).$$

然后构造 $\mathbf{H}[f(\boldsymbol{x})]$ 的近似 \boldsymbol{B} 满足

$$\nabla f(\boldsymbol{x}_k + \Delta \boldsymbol{x}) = \nabla f(\boldsymbol{x}_k) + \boldsymbol{B} \Delta \boldsymbol{x}.$$

上式称作割线方程组。但当 $f(\boldsymbol{x})$ 是定义在多维空间上的函数时，从该式计算 \boldsymbol{B} 将成为一个不定问题（未知数个数比方程式个数多）。此时，构造 \boldsymbol{B} ，根据Newton步长更新当前解的处理需要回归到求解割线方程。几乎不同的拟牛顿法就有不同的选择割线方程的方法。而大多数的方法都假定 \boldsymbol{B} 具有对称性（即满足 $\boldsymbol{B} = \boldsymbol{B}^T$ ）。另外，下表所示的方法可用于求解 \boldsymbol{B}_{k+1} ；在此， \boldsymbol{B}_{k+1} 于某些范数与 \boldsymbol{B}_k 尽量接近。即对于某些正定矩阵 \boldsymbol{V} ，以以下方式更新 \boldsymbol{B} ：

$$\boldsymbol{B}_{k+1} = \arg \min_{\boldsymbol{B}} \|\boldsymbol{B} - \boldsymbol{B}_k\|_{\boldsymbol{V}}.$$

近似Hessian矩阵一般以单位矩阵等作为初期值^[1]。最优化问题的解 \boldsymbol{x}_k 由根据近似所得的 \boldsymbol{B}_k 计算出的Newton步长更新得出。

以下为该算法的总结：

- $\Delta \boldsymbol{x}_k = -\alpha \boldsymbol{B}_k^{-1} \nabla f(\boldsymbol{x}_k)$
- $\boldsymbol{x}_{k+1} = \boldsymbol{x}_k + \Delta \boldsymbol{x}_k$
- 计算新一个迭代点下的梯度 $\nabla f(\boldsymbol{x}_{k+1})$
- 令 $\boldsymbol{y}_k = \nabla f(\boldsymbol{x}_{k+1}) - \nabla f(\boldsymbol{x}_k)$
- 利用 \boldsymbol{y}_k ，直接近似Hessian矩阵的逆矩阵 $\boldsymbol{B}_{k+1}^{-1}$ 。近似的方法如下表：

Method	$B_{k+1} =$	$H_{k+1} = B_{k+1}^{-1} =$
DFP法	$\left(I - \frac{y_k \Delta x_k^T}{y_k^T \Delta x_k}\right) B_k \left(I - \frac{\Delta x_k y_k^T}{y_k^T \Delta x_k}\right) + \frac{y_k y_k^T}{y_k^T \Delta x_k}$	$H_k + \frac{\Delta x_k \Delta x_k^T}{y_k^T \Delta x_k} - \frac{H_k y_k y_k^T H_k^T}{y_k^T H_k y_k}$
BFGS法	$B_k + \frac{y_k y_k^T}{y_k^T \Delta x_k} - \frac{B_k \Delta x_k (B_k \Delta x_k)^T}{\Delta x_k^T B_k \Delta x_k}$	$\left(I - \frac{y_k \Delta x_k^T}{y_k^T \Delta x_k}\right)^T H_k \left(I - \frac{y_k \Delta x_k^T}{y_k^T \Delta x_k}\right) + \frac{\Delta x_k \Delta x_k^T}{y_k^T \Delta x_k}$
Broyden法	$B_k + \frac{y_k - B_k \Delta x_k}{\Delta x_k^T \Delta x_k} \Delta x_k^T$	$H_k + \frac{(\Delta x_k - H_k y_k) \Delta x_k^T H_k}{\Delta x_k^T H_k y_k}$
Broyden族	$(1 - \varphi_k) B_{k+1}^{BFGS} + \varphi_k B_{k+1}^{DFP}, \quad \varphi \in [0, 1]$	
SR1法	$B_k + \frac{(y_k - B_k \Delta x_k)(y_k - B_k \Delta x_k)^T}{(y_k - B_k \Delta x_k)^T \Delta x_k}$	$H_k + \frac{(\Delta x_k - H_k y_k)(\Delta x_k - H_k y_k)^T}{(\Delta x_k - H_k y_k)^T y_k}$

与逆矩阵的关联

若 ***f*** 是一个凸二次函数，且Hessian矩阵 ***B*** 正定，我们总是希望由拟牛顿法生成的矩阵 ***H_k*** 收敛于 Hessian 矩阵的逆 ***H = B⁻¹***。这是基于迭代值更新最小 (least-change update) 的拟牛顿法系列的一个实例。^[2]

实现


拟牛顿法是现在普遍使用的一种最优化算法, 存在多种编程语言的实现方法。

参见

- [牛顿法](#)
- [应用于最优化的牛顿法](#)

参考文献

1. William H. Press. Numerical Recapes. Cambridge Press. 2007: 521–526. ISBN 978–0–521–88068–8.

2. Robert Mansel Gower; Peter Richtarik. Randomized Quasi–Newton Updates are Linearly Convergent Matrix Inversion Algorithms. 2015. arXiv:1602.01768  [math.NA].

取自“<https://zh.wikipedia.org/w/index.php?title=擬牛頓法&oldid=80789048>”

■